SCHÉMA D'ARCHITECTURE · APPLICATION LIVRÉE

Coach d'ouvertures : architecture de l'application

Schéma d'architecture, composants, flux, graphe de l'agent, données, ports et configuration de la solution livrée

Destinataires	jury, équipe technique FFE, toute personne qui reprend le projet
Version décrite	branche `main`, 23 octobre 2026
Lecture	2 schémas en pages paysage (ensemble, graphe de l'agent), 5 tableaux
Documents de détail	`docs/fonctionnalites.md` (guide de A à Z), `docs/deploiement.md`, `docs/contrat-tools.md`, `docs/outil-rag.md`, `docs/outil-videos.md`, `docs/frontend.md`

Sommaire

Résumé
1 Schéma d'ensemble
2 Les composants
3 Les flux principaux
4 Le graphe de l'agent
5 Les sept outils
6 Données et persistance
7 Ports, configuration et secrets
8 Choix d'architecture et limites

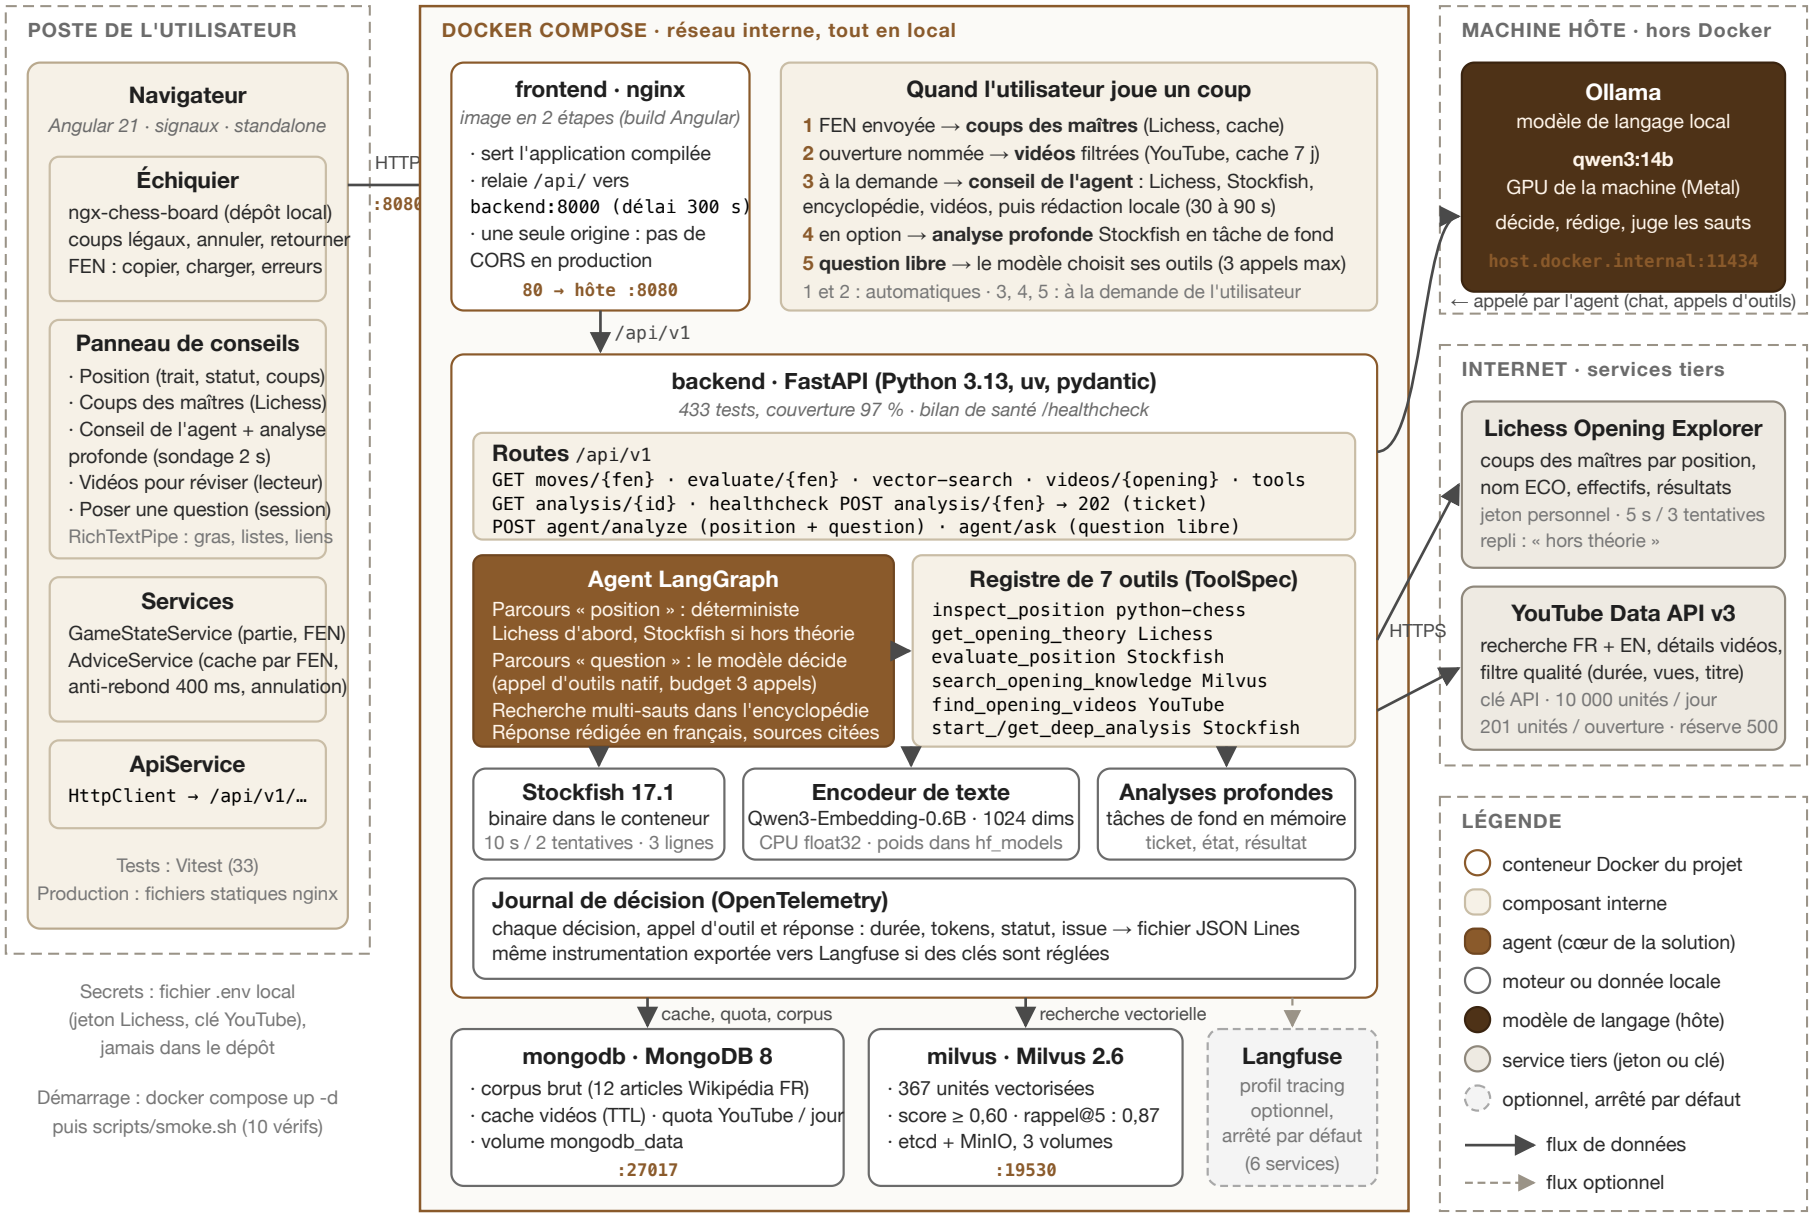
Fédération française des échecs · projet « coach d'ouvertures »

Résumé

L'application tient en **quatre zones** : le navigateur de l'utilisateur (Angular), une pile Docker Compose entièrement locale (nginx, FastAPI avec l'agent et ses outils, MongoDB, Milvus), le modèle de langage servi par **Ollama sur la machine hôte** pour profiter du GPU, et deux **services tiers** interrogés par HTTPS (Lichess, YouTube). Le cœur est un **agent LangGraph** qui, selon qu'on lui donne une position ou une question, suit un parcours déterministe ou choisit ses outils parmi un registre de sept. Tout ce qui est produit par l'agent est journalisé (décisions, appels, durées, tokens) ; l'export vers Langfuse reste optionnel.

1. Schéma d'ensemble

Le schéma ci-après se lit de gauche à droite : l'utilisateur, la pile Docker, puis ce qui est hors de Docker (modèle local, Internet). Les flèches pleines sont des flux de données réels ; les flèches pointillées sont optionnelles. Les ports indiqués sont ceux exposés sur la machine hôte par défaut (modifiables dans `.env`).



Architecture de l'application : navigateur Angular, pile Docker Compose (nginx, FastAPI et agent, MongoDB, Milvus), Ollama sur l'hôte, services tiers Lichess et YouTube

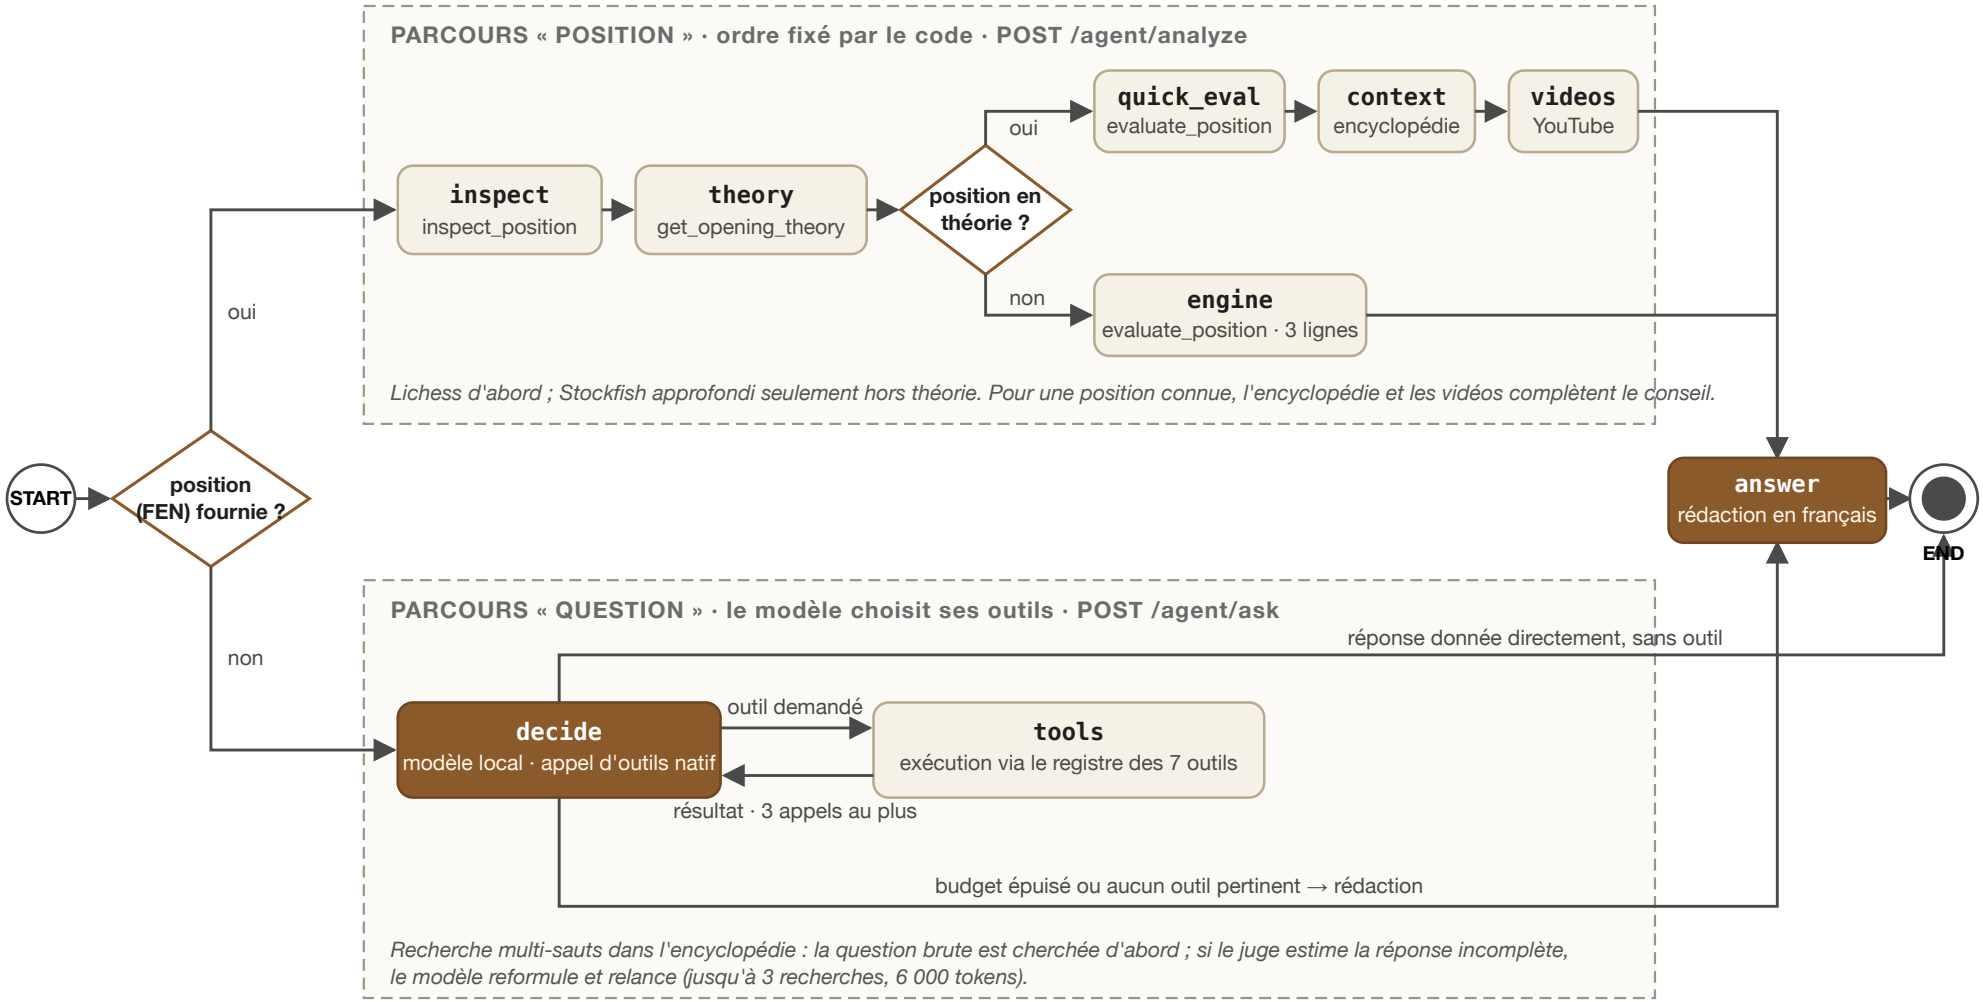
2. Les composants

Composant	Rôle	Technologie	Où il tourne
Navigateur	échiquier, panneau de conseils, appels à l'API	Angular 21 (signaux, standalone), ngx-chess-board, Vitest	poste de l'utilisateur
frontend	sert l'application compilée, relaie `/api/` vers le backend (une seule origine, délai 300 s)	nginx, image en deux étapes	conteneur `p13-frontend`
backend	API REST, agent, registre d'outils, moteurs locaux, journal	FastAPI, Python 3.13, uv, pydantic, LangGraph, langchain-ollama, OpenTelemetry	conteneur `p13-backend`
Stockfish 17.1	évaluation rapide, lignes principales, analyses profondes en tâche de fond	binaire Debian dans l'image backend	conteneur `p13-backend`
Encodeur de texte	vectorise les questions pour la recherche dans l'encyclopédie	Qwen3-Embedding-0.6B (1024 dimensions), CPU float32, poids dans le volume `hf_models`	conteneur `p13-backend`
mongodb	corpus brut, cache des vidéos, compteur de quota YouTube	MongoDB 8, volume `mongodb_data`	conteneur `p13-mongodb`
milvus	index vectoriel de l'encyclopédie (367 unités)	Milvus 2.6 standalone, etcd, MinIO	conteneurs `p13-milvus`, `p13-milvus-etcd`, `p13-milvus-minio`
Ollama	modèle de langage qwen3:14b : décide, rédige, juge les sauts de recherche	Ollama, GPU de la machine	machine hôte, `host.docker.internal:11434`
Lichess Opening Explorer	coups des maîtres, nom et code ECO de l'ouverture	API HTTPS, jeton personnel	Internet
YouTube Data API v3	recherche et détails des vidéos, filtrées côté backend	API HTTPS, clé, quota de 10 000 unités par jour	Internet
Langfuse	visualisation des traces	profil Compose `tracing` (6 services), arrêté par défaut	conteneurs optionnels

3. Les flux principaux

1. **Jouer un coup.** Le front calcule la FEN et appelle `GET /moves/{fen}`. Le backend interroge Lichess (cache par position, 5 s, 3 tentatives) et renvoie l'ouverture, les coups des maîtres et leurs résultats. Si Lichess ne répond pas, la position est marquée « hors théorie » et l'application continue.
2. **Vidéos.** Dès qu'une ouverture est nommée, le front appelle `GET /videos/{opening}`. Le backend lit d'abord le cache MongoDB ; sinon il lance deux recherches (français, anglais), récupère les détails, filtre (3 à 45 min, au moins 1 000 vues, titre pertinent, langue) et décrémente le quota du jour. Sous la réserve de 500 unités, il ne cherche plus.
3. **Conseil de l'agent.** `POST /agent/analyze` entre dans le parcours « position » du graphe : inspection locale, Lichess, puis Stockfish rapide ou approfondi selon que la position est en théorie, encyclopédie et vidéos, enfin rédaction par le modèle local. La réponse contient le texte, l'évaluation, les lignes, les extraits et les appels d'outils effectués.
4. **Analyse profonde.** `POST /analysis/{fen}` renvoie un ticket (202) ; Stockfish travaille en tâche de fond ; le front sonde `GET /analysis/{id}` toutes les deux secondes.
5. **Question libre.** `POST /agent/ask` entre dans le parcours « question » : le modèle choisit lui-même ses outils (trois appels au plus), avec recherche multi-sauts dans l'encyclopédie, puis rédige. L'identifiant de session relie les tours d'une conversation.

4. Le graphe de l'agent



Graphe LangGraph : aiguillage sur la présence d'une FEN ; parcours position déterministe (inspect, theory, quick_eval ou engine, context, videos, answer) ; parcours question (decide, tools en boucle, answer)

Le parcours « position » est **déterministe** : l'ordre des outils est fixé par le code, le modèle n'intervient qu'à la rédaction. Le parcours « question » est **agentique** : à chaque tour, le modèle reçoit la description des sept outils et décide d'en appeler un, de répondre directement ou de rédiger ; un budget de trois appels évite les boucles. Dans les deux cas, le nœud `answer` produit un texte en français avec les sources citées.

5. Les sept outils

Outil	Service	Entrée → sortie	Résilience
`inspect_position`	python-chess (local)	FEN → trait, matériel, statut, coups légaux	aucune dépendance
`get_opening_theory`	Lichess	FEN → ouverture, ECO, coups des maîtres, résultats	5 s, 3 tentatives, cache
`evaluate_position`	Stockfish	FEN, profondeur → évaluation, lignes	10 s, 2 tentatives
`search_opening_knowledge`	encodeur + Milvus	question → passages (score ≥ 0,60)	seuil, repli « aucun passage »
`find_opening_videos`	YouTube + MongoDB	ouverture → vidéos filtrées	8 s, 2 tentatives, cache, quota
`start_deep_analysis`	Stockfish (tâche de fond)	FEN → ticket	file en mémoire
`get_deep_analysis`	tâches en mémoire	ticket → état, résultat	expiration

Chaque outil est déclaré une fois (`ToolSpec` : nom, description, schéma pydantic des paramètres, fonction) et exposé de trois façons : au graphe LangGraph, comme outil LangChain au modèle, et comme route REST pour le front et la documentation Swagger.

6. Données et persistance

Donnée	Où	Volume Docker	Durée de vie
Corpus brut (12 articles Wikipédia FR)	MongoDB	`mongodb_data`	permanent, ré-ingérable par script
Unités vectorisées (367, 1024 dimensions)	Milvus	`milvus_data`, `milvus_etcd`, `milvus_minio`	permanent, reconstruit à l'ingestion
Cache des vidéos par ouverture	MongoDB `video_cache`	`mongodb_data`	TTL configurable (7 jours par défaut)
Quota YouTube consommé	MongoDB `youtube_quota`	`mongodb_data`	un document par jour (fuseau Pacifique)
Poids de l'encodeur	fichiers Hugging Face	`hf_models`	téléchargés une fois
Journal de décision	fichier JSON Lines + mémoire	aucun (dans le conteneur)	durée de vie du conteneur
Analyses profondes	mémoire du processus	aucun	expiration, perdues au redémarrage
Cache des coups des maîtres	mémoire du processus	aucun	durée de vie du conteneur

7. Ports, configuration et secrets

Variable (`.env`)	Défaut	Rôle
`FRONTEND_PORT`	8080	port de l'application dans le navigateur
`BACKEND_PORT`	8001	API exposée sur l'hôte (le front passe par nginx, pas par ce port)
`MONGO_PORT`, `MILVUS_PORT`	27017, 19530	accès direct pour le développement et les tests
`OLLAMA_BASE_URL`	`http://host.docker.internal:11434`	modèle de langage sur l'hôte

Variable (`.env`)	Défaut	Rôle
`AGENT_MODEL`	`qwen3:14b`	modèle utilisé par l'agent
`EMBEDDING_DTYPE`	`float32` dans Docker	précision de l'encodeur (bfloat16 est 30 fois plus lent sur CPU)
`LICHESS_TOKEN`, `YOUTUBE_API_KEY`	vides	secrets ; sans jeton Lichess, limite de débit plus basse ; sans clé YouTube, carte Vidéos vide
`LANGFUSE_PUBLIC_KEY`, `LANGFUSE_SECRET_KEY`	vides	traces exportées seulement si réglées (profil `tracing`)
`CORS_ORIGINS`	`http://localhost:4200`	développement du front hors Docker

Les secrets vivent dans `.env`, ignoré par git ; `.env.example` documente chaque variable avec une valeur vide qui laisse jouer le défaut. Le démarrage se fait avec `docker compose up -d`, et `scripts/smoke.sh` vérifie dix points de bout en bout (santé, base, Lichess, Stockfish, recherche vectorielle, vidéos, agent, front).

8. Choix d'architecture et limites

- **Tout en local, sauf le modèle.** Les conteneurs n'ont pas accès au GPU du Mac ; Ollama reste sur l'hôte et le backend le joint par `host.docker.internal`. Sur un serveur Linux avec GPU, Ollama peut rejoindre la pile Compose sans changer le code.
- **Une seule origine.** nginx relaie l'API : pas de CORS en production, un seul port à ouvrir, délai de 300 s pour le conseil complet.
- **Déterministe quand c'est possible.** Le parcours « position » n'a pas besoin que le modèle choisisse : l'ordre Lichess puis Stockfish est fixé, ce qui rend les réponses prévisibles et mesurables. Le choix d'outils est réservé aux questions libres.
- **Dégradation progressive.** Chaque service tiers a un délai, des tentatives et un repli ; l'absence d'une clé n'empêche pas l'application de démarrer.
- **Limites.** Analyses profondes et journal ne survivent pas au redémarrage du conteneur ; un seul modèle est servi à la fois ; les mesures ont été faites sur une machine, pas en charge multi-utilisateurs ; le mode « jouer contre l'agent » n'est pas implémenté.