NOTE DE SYNTHÈSE · SYSTÈME LIVRÉ

Coach d'ouvertures : bénéfices et limites du système développé

Agent IA d'apprentissage des ouvertures aux échecs : schéma d'architecture technique, étude de faisabilité et estimation des coûts

Destinataires	Responsable produit FFE, direction technique, jury
Auteur	Teddy Moustapha Traoré
Système décrit	branche `main` du dépôt, 5 novembre 2026
Statut	Système **implémenté**, démontré en local avec `docker compose`
Dépôt	`https://github.com/traoreteddy/openclassroom-p13`
Décision demandée	Choisir le scénario de mise à disposition (§ 5.3) et le périmètre de la suite (§ 6)

Sommaire

Résumé pour décision

1 Contexte et périmètre du système livré

2 Schéma d'architecture technique

3 Bénéfices

4 Limites et risques

5 Étude de faisabilité et estimation des coûts

6 Recommandations

Sources

Résumé pour décision

Le système livré est un **coach d'ouvertures** pour les jeunes joueurs de la Fédération : un échiquier dans le navigateur, et un agent qui, à chaque coup, nomme l'ouverture, montre les coups des maîtres, évalue la position, cite l'encyclopédie et propose des vidéos. Il répond aussi aux questions libres (« quelles sont les idées de la Caro-Kann ? ») en choisissant lui-même ses outils. Tout tourne en local : conteneurs Docker pour l'application et ses bases, modèle de langage sur la machine hôte, aucune donnée de joueur envoyée à un fournisseur d'IA.

Ce que nous avons établi :

- **Le système fonctionne de bout en bout et se mesure.** Depuis une installation fraîche, dix vérifications sur dix passent en conteneurs ; 433 tests backend (97 % de couverture) et 33 tests front tournent sans réseau. L'agent choisit le bon outil dans 97 % des cas (29 demandes sur 30) et retrouve l'extrait attendu de l'encyclopédie dans 87 % des questions de référence.
- **Le coût de fonctionnement est faible, le coût caché est la latence.** En local, l'inférence ne coûte rien ; le même trafic chez un fournisseur de petits modèles coûterait quelques euros par mois. En revanche un conseil complet prend 20 à 90 s avec le modèle local qwen3:14b, et 13 à 28 s pour une question libre.
- **Les limites sont connues et bornées.** Le modèle peut inventer l'« idée » d'un coup absente des sources ; l'encyclopédie couvre 12 ouvertures ; les analyses longues ne survivent pas à un redémarrage ; les mesures ont été faites sur une machine, sans charge multi-utilisateurs ; le mode « jouer contre l'agent » n'est pas implémenté.
- **Trois scénarios de mise à disposition** sont chiffrés (§ 5) : poste local en club (≈ 0 € par mois), serveur FFE avec GPU (≈ 650 à 750 € par mois), ou VM légère plus modèle en cloud (≈ 80 à 200 € par mois selon l'usage).

97 %	0,87	10 / 10	0 €
Bon outil choisi par l'agent (Tâches-30, qwen3:14b)	Rappel de l'encyclopédie (Réf-30, 1,2 recherche par question)	Vérifications de bout en bout depuis une installation fraîche	Coût d'inférence en local (5 à 120 € par mois en cloud)

Recommandation : mettre le système entre les mains d'un premier club en scénario « poste local », mesurer l'usage réel pendant un mois, puis décider du passage en serveur. Consacrer la suite immédiate aux deux limites qui touchent la pédagogie : l'invention d'idées par le modèle et l'étendue de l'encyclopédie.

1. Contexte et périmètre du système livré

La Fédération veut un outil pour apprendre les ouvertures aux jeunes espoirs sans mobiliser un entraîneur à chaque coup. Le système livré répond à deux usages :

Usage	Ce que fait le système	Parcours interne
Jouer et comprendre : l'utilisateur joue des coups sur l'échiquier	nomme l'ouverture et son code ECO, affiche les coups des maîtres et leurs résultats, évalue la position (Stockfish), rédige un conseil court appuyé sur l'encyclopédie, propose des vidéos en français	parcours « position », **déterministe** : l'ordre des outils est fixé, le modèle ne fait que rédiger
Poser une question : « pourquoi 3.Fc4 dans l'Italienne ? »	choisit lui-même les outils utiles (jusqu'à trois appels), cherche dans l'encyclopédie en plusieurs sauts si besoin, répond en citant les passages	parcours « question », **agentique**

L'agent dispose de **sept outils** : inspection locale de la position, coups des maîtres (Lichess), évaluation (Stockfish), recherche dans l'encyclopédie (12 articles Wikipédia FR vectorisés dans Milvus), vidéos (YouTube), lancement et suivi

d'une analyse profonde en tâche de fond. Chaque outil est déclaré une fois (nom, description pour le modèle, schéma des paramètres, politique de résilience) et exposé à la fois au modèle, au graphe de l'agent et à l'API REST.

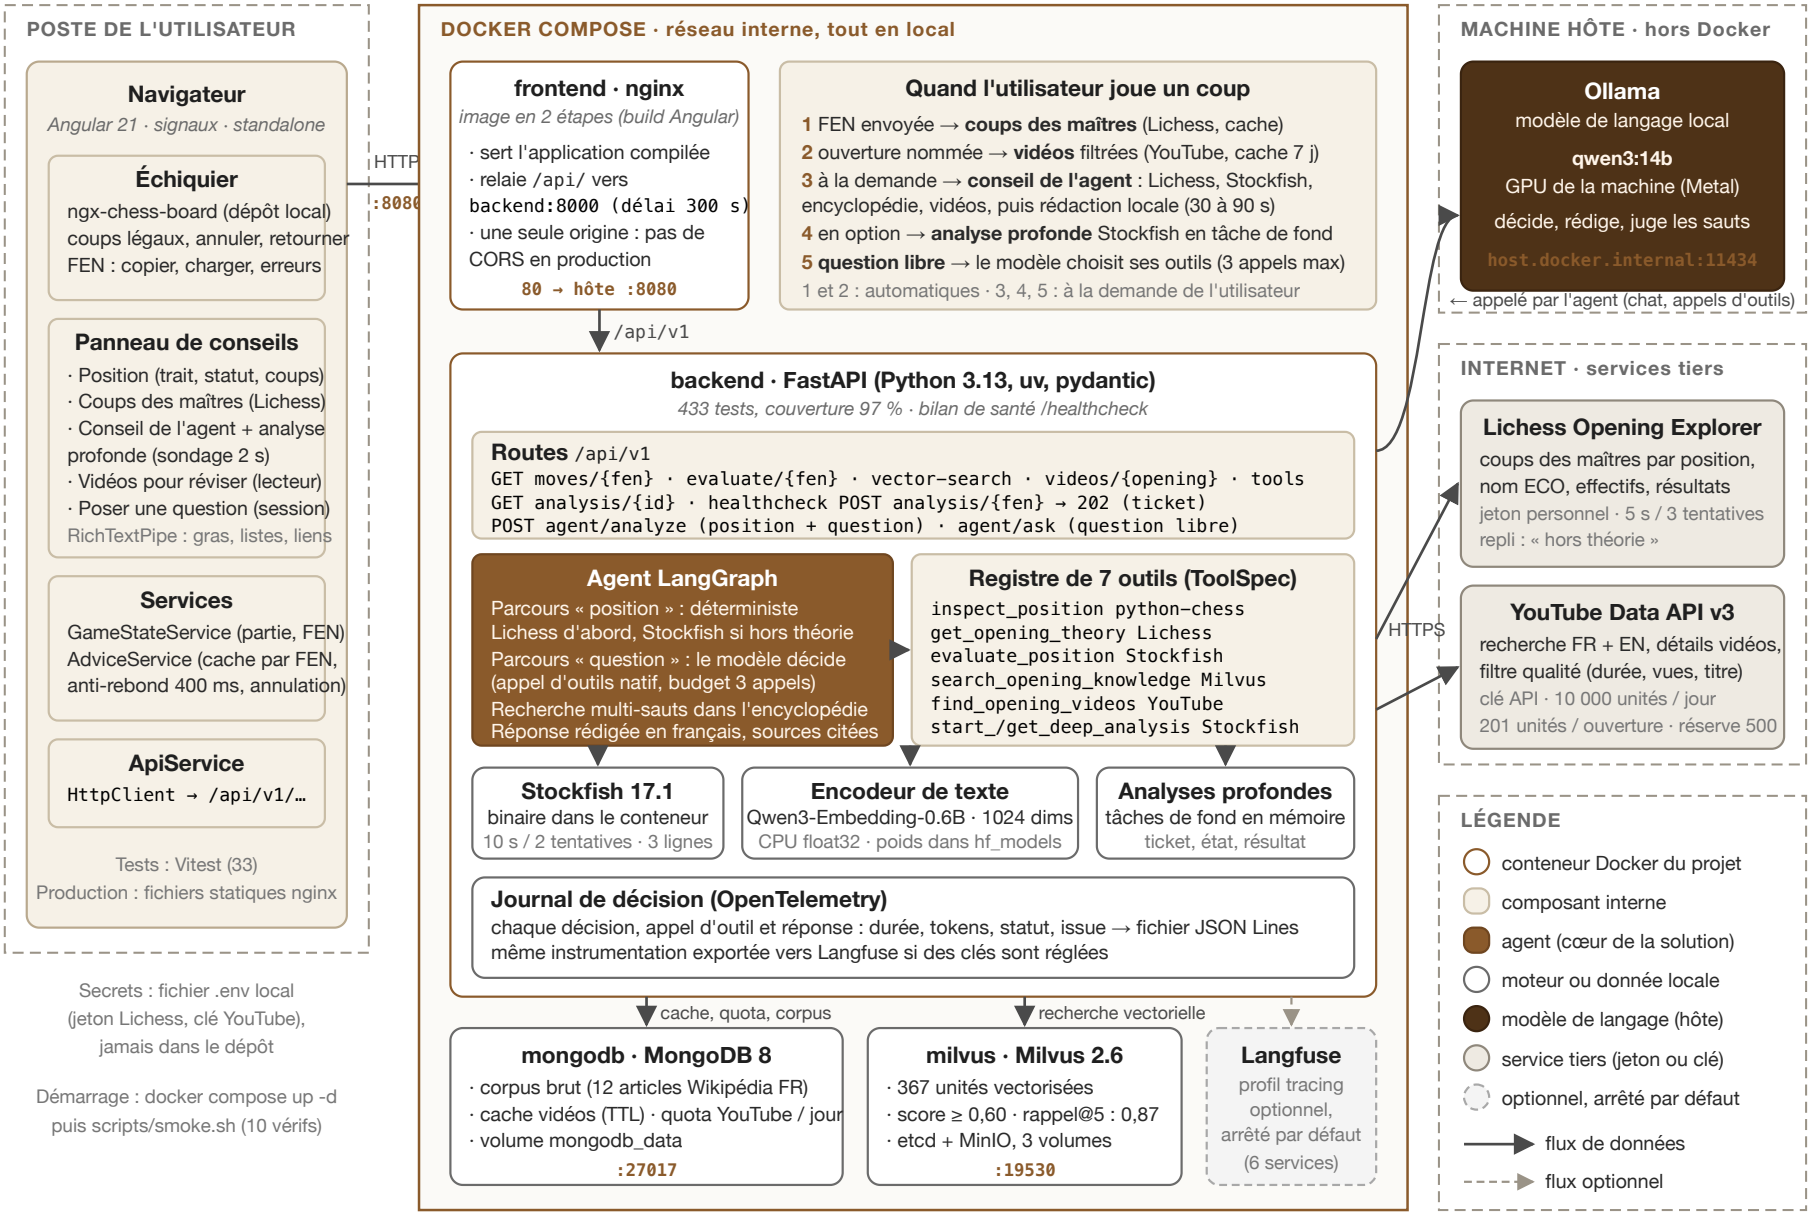
Périmètre livré : code source, conteneurs `docker compose` (front, API, MongoDB, Milvus), script d'ingestion du corpus, scripts de mesure, traces et journal de décision. Hors périmètre : comptes utilisateurs, suivi de progression, mode « jouer contre l'agent », recherche de vidéos par position (étudiée séparément, non implémentée).

2. Schéma d'architecture technique

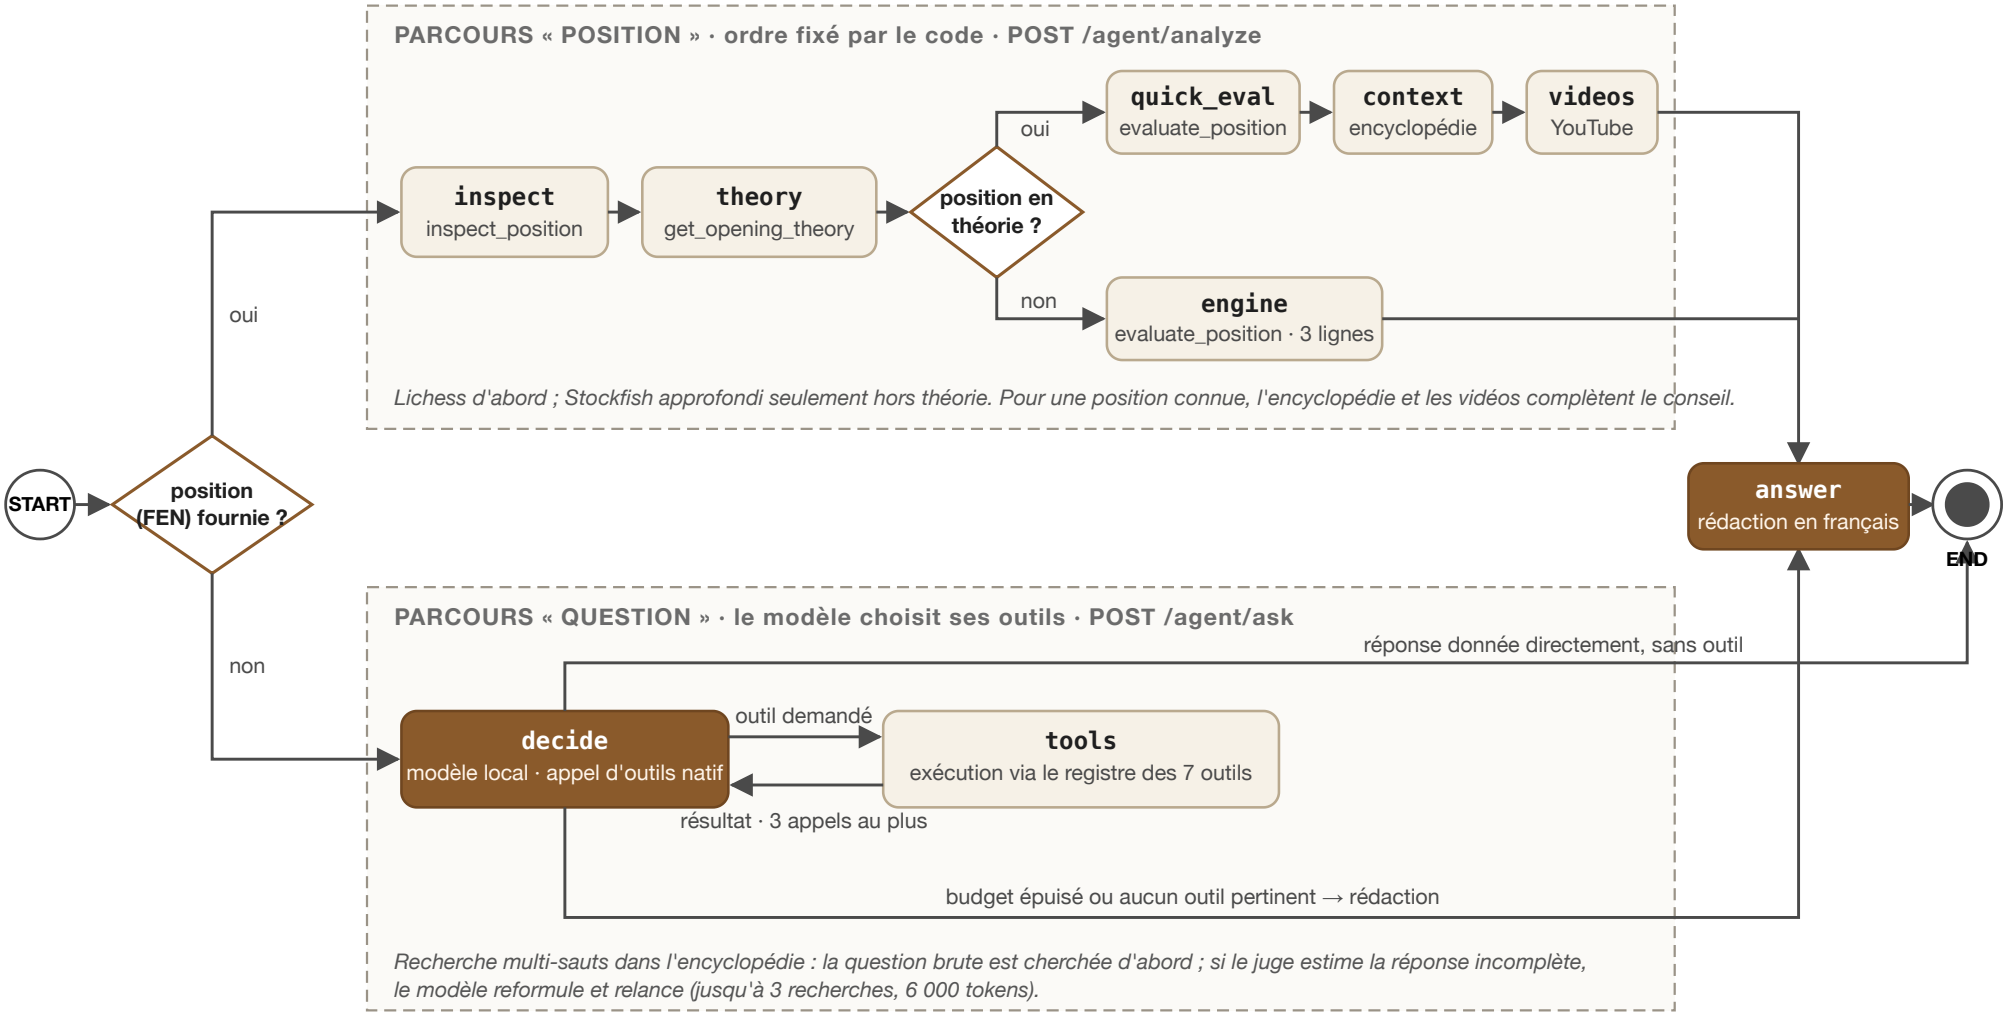
L'application tient en **quatre zones** : le navigateur de l'utilisateur (Angular), une pile Docker Compose entièrement locale (nginx, FastAPI avec l'agent et ses outils, MongoDB, Milvus), le modèle de langage servi par **Ollama sur la machine hôte** pour profiter du GPU, et deux **services tiers** interrogés par HTTPS (Lichess, YouTube). Les deux schémas en pages paysage se lisent de gauche à droite ; les flèches pointillées sont optionnelles ; les ports sont ceux exposés par défaut sur la machine hôte.

2.1 Composants

Composant	Rôle	Technologie	Où il tourne
Navigateur	échiquier, panneau de conseils, appels à l'API	Angular 21, ngx-chess-board	poste de l'utilisateur
frontend	sert l'application compilée, relaie `/api/` vers le backend (une seule origine)	nginx	conteneur
backend	API REST, agent, registre d'outils, moteurs locaux, journal	FastAPI, Python 3.13, LangGraph, OpenTelemetry	conteneur
Stockfish 17.1	évaluation rapide, lignes principales, analyses profondes en tâche de fond	binaire dans l'image backend	conteneur backend
Encodeur de texte	vectorise les questions pour la recherche dans l'encyclopédie	Qwen3-Embedding-0.6B (1 024 dimensions)	conteneur backend
mongodb	corpus brut, cache des vidéos, compteur de quota YouTube	MongoDB 8	conteneur
milvus	index vectoriel de l'encyclopédie (367 unités)	Milvus 2.6, etcd, MinIO	conteneurs
Ollama	modèle qwen3:14b : décide, rédige, juge les sauts de recherche	Ollama, GPU de la machine	machine hôte
Lichess Opening Explorer	coups des maîtres, nom et code ECO	API HTTPS, jeton personnel	Internet
YouTube Data API v3	recherche et détails des vidéos	API HTTPS, clé, 10 000 unités par jour	Internet
Langfuse	visualisation des traces	profil Compose optionnel, arrêté par défaut	conteneurs optionnels



Architecture de l'application : navigateur Angular, pile Docker Compose (nginx, FastAPI et agent, MongoDB, Milvus), Ollama sur l'hôte, services tiers Lichess et YouTube



Graphe LangGraph : aiguillage sur la présence d'une FEN ; parcours position déterministe (inspect, theory, quick_eval ou engine, context, videos, answer) ; parcours question (decide, tools en boucle, answer)

2.2 Lecture du graphe

Le parcours « position » enchaîne inspection, Lichess, puis Stockfish rapide (en théorie) ou approfondi (hors théorie, ou Lichess en panne), encyclopédie et vidéos si l'ouverture a un nom, et rédaction. Le parcours « question » boucle entre décision du modèle et exécution d'outils, avec un budget de trois appels. Chaque étape est un span OpenTelemetry : le journal de décision (fichier JSON Lines) et Langfuse en découlent.

2.3 Résilience et données

Chaque service tiers a un délai, des tentatives et un repli : Lichess 5 s et 3 tentatives avec cache par position ; YouTube 8 s, cache MongoDB 7 jours et refus de chercher sous une réserve de 500 unités de quota ; Stockfish 10 s et redémarrage du moteur après un plantage ; disjoncteur par outil. Une erreur d'outil revient au modèle comme un message et ne bloque jamais la réponse. Les données persistantes (corpus, index, cache, poids de l'encodeur) vivent dans des volumes Docker ; le journal de décision, les analyses profondes et le cache Lichess vivent dans le conteneur et disparaissent avec lui.

3. Bénéfices

Bénéfice	Pour qui	Preuve ou mesure
Un retour immédiat sur chaque coup, sans entraîneur : nom de l'ouverture, coups des maîtres, évaluation, conseil rédigé	le jeune joueur	parcours démontré sur quatre positions types (en théorie, Sicilienne, hors théorie, FEN invalide)
Des réponses sourcées, pas de mémoire du modèle : l'agent cite les passages de l'encyclopédie et les statistiques Lichess	le joueur, l'entraîneur qui relit	rappel 0,87 sur Réf-30 ; recall@5 de 0,90 sur 50 requêtes contre 0,78 pour le RAG de départ
Des vidéos en français, filtrées (durée 3 à 45 min, au moins 1 000 vues, titre pertinent)	le joueur qui révise	10 ouvertures sur 10 avec vidéos, 86 % des titres nomment l'ouverture, 100 % en français
Un agent qui sait quand ne pas chercher : salutations et questions hors échecs répondues sans outil	la qualité et le coût	0 appel inutile sur 6 questions hors sujet et 6 relevant d'un autre outil ; 97 % de bon outil sur Tâches-30
Souveraineté des données : aucune donnée de joueur ne sort de la machine, modèle de langage local	la Fédération (RGPD, mineurs)	architecture § 2 ; seuls une FEN et un nom d'ouverture partent vers Lichess et YouTube
Reproductible et vérifiable : installation en une commande, test de bout en bout, journal de chaque décision	l'équipe technique	services sains en moins de 2 min, `smoke.sh` 10 / 10, journal et traces Langfuse
Robuste aux pannes des services tiers	tous	94 % d'appels réussis sous 30 % de pannes simulées, contre 72 % sans les politiques de résilience
Coût marginal nul par conversation en local	la Fédération	0 € d'inférence ; équivalent cloud inférieur à 0,01 € pour 30 décisions

4. Limites et risques

4.1 Limites pédagogiques

Limite	Analyse	Parade envisagée
Le modèle peut inventer l'« idée » d'un coup absente des données	observé sur des positions en théorie : les statistiques sont justes, l'explication parfois plausible mais non sourcée	ne rédiger l'idée que si un passage de l'encyclopédie la contient ; sinon dire « pas d'explication disponible »
Encyclopédie limitée : 12 ouvertures, Wikipédia FR	hors de ces ouvertures, l'agent n'a que Lichess et Stockfish ; 4 questions de Réf-30 sur 30 restent introuvables (variantes nommées dans des listes)	étendre le corpus (contenus FFE, cours d'entraîneurs) ; index lexical complémentaire
Pas de suivi du joueur : ni compte, ni historique, ni progression	chaque session repart de zéro ; impossible d'adapter le niveau	à cadrer avec la direction pédagogique avant tout développement

Limite	Analyse	Parade envisagée
Conseil en français uniquement, niveau de langue non réglé selon l'âge	le prompt vise « clair et court » sans distinguer 8 ans et 16 ans	profil d'âge dans le prompt, validation par des entraîneurs

4.2 Limites techniques

Limite	Probabilité	Impact	Parade
Latence : 20 à 90 s pour un conseil complet, 13 à 28 s pour une question libre, avec qwen3:14b sur GPU Mac	certaine	attente visible ; un enfant décroche	modèle cloud (quelques secondes), affichage progressif des cartes (déjà en place : coups et vidéos arrivent avant le conseil)
Un seul modèle, une seule machine : pas de mesure en charge multi-utilisateurs	élevée dès 5 utilisateurs simultanés	files d'attente sur Ollama et Stockfish	serveur GPU dédié ou API cloud ; limiter les analyses profondes concurrentes
Analyses profondes et journal en mémoire	certaine au redémarrage	tâches perdues, journal tronqué	persistance MongoDB (quelques jours de travail)
Dépendance à Lichess et YouTube : limites de débit, quota de 10 000 unités par jour (49 recherches non cachées)	moyenne	positions « hors théorie » par défaut, carte Vidéos vide	cache déjà en place ; demande d'extension de quota ; dégradation progressive assumée
Encodeur lent sur CPU : ingestion en 5 min dans le conteneur contre 30 s sur GPU	faible (ingestion ponctuelle)	aucun en usage courant	float32 imposé par le compose ; ingestion depuis l'hôte
Pas d'authentification sur l'API	certaine en exposition réseau	usage abusif, consommation du quota	reverse proxy avec authentification avant toute exposition hors d'un poste local

4.3 Risques d'exploitation

Risque	Analyse	Parade
Conditions d'utilisation des services tiers	Lichess et YouTube sont utilisés par leurs API officielles, avec jeton et clé ; le corpus Wikipédia est sous CC BY-SA, attribution conservée	revue annuelle des conditions ; sources citées dans chaque réponse
Dérive du modèle ou de ses dépendances	une mise à jour d'Ollama ou du modèle peut changer la qualité des décisions	versions épinglées ; relancer Tâches-30 et Réf-30 à chaque changement (scripts livrés)
Coût humain de l'encyclopédie	la valeur pédagogique vient du corpus, pas du code	prévoir un relecteur échecs pour chaque ajout

5. Étude de faisabilité et estimation des coûts

5.1 Ce qui est prouvé

Critère	Mesure	Source
Fonctionnement de bout en bout en conteneurs	installation fraîche : services sains en 112 à 119 s, ingestion de 367 unités en 5 à 8 min, `smoke.sh` 10 / 10, persistance après `down` / `up`	test du 23 octobre 2026
Qualité du code	433 tests backend, 97 % de couverture (branches comprises), sans réseau ; 33 tests front	`pytest --cov`, Vitest
Choix de l'outil par l'agent	97 % (29 / 30) avec qwen3:14b en appel natif, contre 73 % pour phi4-mini et 70 % pour qwen3:1.7b	Tâches-30
Appels inutiles de la recherche	4 sur 20 questions hors corpus, toutes sur des sujets d'échecs absents du corpus (inévitable sans connaître son contenu) ; 0 sur les questions hors sujet	Décision-50
Rappel de l'encyclopédie	0,87 sur Réf-30 ; recall@5 de 0,90 sur 50 requêtes (0,78 au départ) ; 1,2 recherche par question, budget jamais dépassé	Réf-30, Multi-10, Holdout-20

Critère	Mesure	Source
Vidéos	10 ouvertures sur 10, 86 % de titres pertinents, 100 % en français	mesure sur 10 ouvertures
Résilience	94 % d'appels réussis sous 30 % de pannes simulées (72 % sans politiques)	300 tours simulés
Latence	décision 3,1 s ; conseil complet 20 à 90 s ; question libre 13 s (un passage) à 28 s (multi-sauts)	journal de décision

5.2 Prérequis machine

Ressource	Besoin	Remarque
Mémoire	8 Go pour Docker, plus 9 à 10 Go pour qwen3:14b dans Ollama	un poste de 24 Go est confortable, 16 Go est le minimum
GPU	recommandé pour le modèle (Apple Silicon ou carte NVIDIA)	sans GPU, le conseil passe à plusieurs minutes
Disque	6 Go d'images et de données, 1,2 Go d'encodeur, 9 Go de modèle	volumes observés : MongoDB 231 Mo, Milvus 156 Mo
Réseau	accès HTTPS à Lichess et YouTube	fonctionne sans, en mode dégradé

5.3 Scénarios de mise à disposition

Scénario	Description	Pour qui	Points d'attention
A. Poste local (configuration livrée)	un ordinateur par club ou par entraîneur, tout en local	premiers clubs pilotes, démonstrations	un utilisateur à la fois ; installation par une personne technique
B. Serveur FFE avec GPU	la pile Compose et Ollama sur un serveur Linux avec GPU ; le code ne change pas	déploiement fédéral, souveraineté totale	coût fixe du GPU ; authentification à ajouter
C. VM légère et modèle en cloud	la pile Compose sur une petite VM, le modèle appelé par API chez un fournisseur	montée en charge rapide, latence de quelques secondes	questions des joueurs envoyées au fournisseur (contrat, mineurs) ; coût variable

5.4 Hypothèses de coût

Paramètre	Hypothèse basse	Hypothèse haute
Utilisateurs actifs par mois	200	2 000
Tours de conversation par utilisateur et par mois	20	30
Tours par mois	4 000	60 000
Tokens par tour (entrée / sortie)	3 000 / 400 (conseil sur une position : une rédaction)	9 000 / 700 (question libre : jusqu'à 3 décisions à ≈ 2 000 tokens, puis rédaction)
Tarif d'un petit modèle hébergé	0,14 € / 0,55 € par million de tokens (entrée / sortie), hypothèse du journal de décision	idem
Tarif d'un modèle de classe supérieure	environ dix fois plus	idem
GPU à la demande (classe L4)	0,9 € par heure, soit ≈ 650 € par mois en continu	idem
VM 4 vCPU / 16 Go	60 à 80 € par mois	idem

Les prix sont des ordres de grandeur relevés en octobre 2026 chez des fournisseurs européens ; ils varient de 10 à 20 % selon la région et le mode de facturation.

5.5 Coûts de fonctionnement par mois

Poste	Scénario A : poste local	Scénario B : serveur GPU	Scénario C : VM + cloud
Machine	0 € (poste existant) ; sinon amortissement d'un poste à 2 000 € sur 4 ans ≈ 40 €	650 à 700 € (GPU en continu)	60 à 80 € (VM)

Poste	Scénario A : poste local	Scénario B : serveur GPU	Scénario C : VM + cloud
Inférence du modèle	0 €	0 €	5 à 15 € (petit modèle, hypothèse basse) ; 60 à 120 € (hypothèse haute) ; × 10 pour un modèle de classe supérieure
API Lichess, YouTube	0 € (jeton et clé gratuits, dans les quotas)	0 € ; extension de quota YouTube à demander au-delà de 49 recherches non cachées par jour	idem
Sauvegardes, supervision	0 €	10 à 20 €	10 à 20 €
Maintenance humaine	0,5 jour	1 à 2 jours	1 à 2 jours
Total machine	**≈ 0 à 40 €**	**≈ 660 à 720 €**	**≈ 80 à 200 €** (jusqu'à 1 300 € avec un grand modèle en hypothèse haute)

Lecture : le scénario B achète la souveraineté au prix d'un GPU qui tourne même la nuit ; le scénario C est le moins cher tant que l'usage reste modéré et que le contrat avec le fournisseur couvre des données de mineurs ; le scénario A ne coûte rien et suffit pour valider l'appétence.

5.6 Coûts de la suite (construction)

Le système est construit. Les travaux restants sont estimés en jours de développeur confirmé, avec l'appui ponctuel d'un entraîneur.

Chantier	Contenu	Basse	Haute
1. Fiabilité pédagogique	idée du coup conditionnée aux sources, prompt par tranche d'âge, validation par des entraîneurs sur 30 positions	5	10
2. Encyclopédie	passage de 12 à 40 ouvertures, contenus FFE, index lexical complémentaire, relance des mesures	8	15
3. Exploitation multi-utilisateurs	authentification, persistance des analyses et du journal, limites de concurrence, supervision	10	20
4. Mode « jouer contre l'agent »	coup de l'agent (Stockfish bridé), commentaire après chaque coup	5	10
Total		**28 jours**	**55 jours**

À 500 à 700 € par jour en prestation (350 à 450 € en interne), la suite représente **10 000 à 38 000 €**. Les chantiers 1 et 2 suffisent pour un pilote en club ; le chantier 3 conditionne les scénarios B et C.

5.7 Verdict de faisabilité

Critère	Verdict
Technique	**démontré** : système complet, installé en une commande, mesuré ; incertitude restante sur la tenue en charge
Coût machine	**faible** en scénario A et C ; **significatif** en scénario B (GPU en continu)
Coût humain	**modéré** pour un pilote (13 à 25 jours) ; 28 à 55 jours pour un déploiement fédéral
Juridique et données	**maîtrisé** en local ; à contractualiser en scénario C (données de mineurs)
Valeur pédagogique	**à confirmer en club** : l'usage réel et l'avis des entraîneurs décideront de la suite

6. Recommandations

1. **Pilote en scénario A** dans un ou deux clubs, un mois, avec le journal de décision activé : nombre de tours, questions posées, positions hors théorie, avis des entraîneurs.
2. **Chantiers 1 et 2 en parallèle** (fiabilité pédagogique, encyclopédie) : ce sont les seules limites que les joueurs voient.

3. **Décider du scénario B ou C** à l'issue du pilote, sur des chiffres d'usage réels, et seulement après le chantier 3 (authentification, persistance, concurrence).
4. **Rejouer les mesures livrées** (Tâches-30, Décision-50, Réf-30, vidéos, résilience) à chaque changement de modèle ou de corpus : elles sont scriptées et prennent moins d'une heure.

Sources

- Dépôt du projet : code, `README.md` (installation, démonstration, dépannage), `docker-compose.yml`, `scripts/smoke.sh`, jeux de référence dans `backend/data/eval/`.
- Scripts de mesure dans `backend/scripts/` : `eval_agent.py` (Tâches-30, Décision-50), `eval_retrieval.py`, `eval_agentic_search.py`, `eval_multihop.py`, `validate_holdout.py`, `eval_videos.py`, `bench_resilience.py` ; journal de décision et traces Langfuse.