NOTE DE CADRAGE · SYSTÈME NON IMPLÉMENTÉ

Note de cadrage : retrouver la position exacte dans les vidéos d'ouvertures

Système d'analyse vidéo par vision et serveur MCP « Vision » : bénéfices, limites, architecture, faisabilité et coûts

Destinataire	Responsable produit FFE, direction technique
Auteur	Équipe agent « coach d'ouvertures »
Date	23 octobre 2026
Statut	Note de décision, système **non implémenté**
Décision demandée	Lancer ou non une preuve de faisabilité de 3 semaines (§ 9)

Sommaire

Résumé pour décision
1 Contexte et problème
2 Solution proposée et parcours utilisateur
3 État de l'art : détecter un échiquier et lire la position
4 Architecture technique avec MCP
5 Bénéfices attendus
6 Limites et risques
7 Faisabilité et coûts
8 Alternatives
9 Étapes de développement et recommandation
Sources consultées

Résumé pour décision

Aujourd'hui, l'agent propose des vidéos par recherche textuelle sur le nom de l'ouverture. Un jeune joueur qui veut comprendre le coup qu'il vient de jouer reçoit une vidéo de 20 minutes et doit la parcourir. Le système étudié ici indexe les vidéos **par position** : il retrouve la seconde exacte où l'échiquier affiché montre la position courante et renvoie un lien horodaté.

Ce que nous avons établi :

- **Techniquement faisable** avec des briques connues : les vidéos pédagogiques montrent des échiquiers 2D à l'écran, un cas plus simple que les plateaux filmés traités par la littérature (92 à 99 % de précision par case). Les coûts machine sont faibles : quelques dizaines d'euros pour indexer 500 vidéos, 30 à 80 € par mois pour faire tourner le service.
- **Le vrai coût est humain** : 45 à 75 jours de travail sur quatre phases, dont la constitution d'un jeu de test annoté et la négociation des droits.
- **Le risque principal est juridique, pas technique** : les conditions d'utilisation de YouTube interdisent de télécharger les vidéos. Le catalogue doit se limiter aux vidéos de la FFE, de partenaires qui fournissent leurs fichiers, et aux vidéos sous licence Creative Commons dont le fichier est obtenu auprès du créateur. Cela borne la couverture à quelques centaines, puis quelques milliers de vidéos.
- **Deux alternatives moins chères** existent (transcription audio ; chapitres et PGN fournis par les créateurs) et peuvent être combinées avec la vision.

45 à 75 j	40 à 140 €	10 à 90 €	≥ 90 %
Construction : travail humain (16 000 à 52 000 €)	Construction : machine (GPU, CPU, stockage)	Fonctionnement par mois (GPU à la demande, VM, stockage)	Critère d'arrêt de la preuve de faisabilité (échiquiers exacts)

Recommandation : lancer une preuve de faisabilité de 15 jours sur 20 vidéos annotées à la main, avec un critère d'arrêt chiffré (90 % de positions exactes), avant tout engagement sur le MVP. Ne pas investir dans l'industrialisation sans au moins 300 vidéos sous droits.

1. Contexte et problème

L'agent livré (FastAPI, LangGraph, Milvus, Stockfish, Lichess) appelle l'outil `find_opening_videos` qui interroge l'API YouTube Data v3 avec le nom de l'ouverture (« partie italienne échecs ouverture explication »), filtre les résultats (durée, vues, langue) et renvoie des liens. La mesure sur 10 ouvertures du corpus donne 10 ouvertures sur 10 avec des vidéos, 86 % des titres nommant l'ouverture, 100 % en français.

La limite est structurelle : la recherche texte travaille au niveau de **l'ouverture**, pas de la **position**. Trois conséquences pour un jeune joueur :

Situation	Ce qu'il reçoit	Ce qu'il voudrait
Il vient de jouer 4.Cg5 dans la défense des deux cavaliers	une vidéo de 25 minutes sur l'Italienne	l'instant où le présentateur montre 4.Cg5
Sa position sort de la théorie (plus de nom d'ouverture)	rien, ou du hors-sujet	une vidéo où cette position, ou une très proche, apparaît
Il veut comparer deux plans dans une même variante	la même vidéo deux fois	deux horodatages différents

Le backlog de la FFE décrit la réponse souhaitée : stocker les vidéos pertinentes, analyser chaque vidéo pour en extraire les images, détecter la présence d'un échiquier sur chaque image et convertir la position en notation FEN. La présente note instruit cette demande sans l'implémenter.

2. Solution proposée et parcours utilisateur

2.1 Principe

Un pipeline hors ligne transforme chaque vidéo autorisée en une liste de **segments** : « de la seconde 754 à la seconde 801, l'écran montre la position P ». Ces segments sont rangés dans un index interrogeable par position. En ligne, l'agent demande à un serveur **MCP « Vision »** les segments qui correspondent à la position courante et obtient des liens du type `youtube.com/watch?v=XXX&t=754s`, affichés dans la carte « Vidéos pour réviser » avec le lecteur intégré existant.

2.2 Parcours

1. Le joueur joue 1.e4 e5 2.Cf3 Cc6 3.Fc4 Cf6 4.Cg5 sur l'échiquier.
2. L'agent identifie la position (FEN) et l'ouverture (Lichess), comme aujourd'hui.
3. Il appelle l'outil MCP `find_video_by_fen` avec le **placement des pièces** (premier champ de la FEN).
4. Le serveur renvoie, par exemple : « Défense des deux cavaliers, partie pédagogique 2 », de 12 min 34 s à 13 min 21 s, confiance 0,97 ; et deux autres segments.
5. La carte Vidéos affiche ces segments en tête, avec le lecteur démarrant à 12 min 34 s ; la recherche texte actuelle reste en repli si l'index ne connaît pas la position.

2.3 Ce qu'une image ne dit pas

Une image montre les pièces, pas le trait, les droits de roque ni la prise en passant. L'index porte donc uniquement sur le placement des pièces (64 cases), et deux positions qui ne diffèrent que par le trait sont confondues. C'est acceptable pour l'usage pédagogique : le commentateur montre la position et en parle, quel que soit le trait. Il faut aussi reconnaître l'échiquier **retourné** (vue côté Noirs), fréquent dans les vidéos sur les défenses : chaque placement est indexé sous ses deux orientations.

3. État de l'art : détecter un échiquier et lire la position

3.1 Deux familles de problèmes

Famille	Exemples	Difficulté	Notre cas
Plateau physique filmé (photos, caméra de tournoi)	LiveChess2FEN, chesscog, CVChess, ChessReD	perspective, éclairage, occultations, pièces 3D	rare dans les vidéos pédagogiques
Échiquier 2D affiché à l'écran (Lichess, Chess.com, logiciels d'analyse)	jeux de données d'échiquiers rendus (100 000 images, 28 styles de plateau, 32 styles de pièces)	grille parfaitement régulière ; variété des thèmes ; flèches, surlignages, curseur par-dessus	**cas majoritaire**

Les vidéos d'ouvertures en français sont presque toutes des captures d'écran commentées : le problème à résoudre est le second, nettement plus simple.

3.2 Résultats publiés

Travail	Approche	Résultat rapporté	Enseignement
LiveChess2FEN (2020, code ouvert)	détection du plateau, puis classification de chaque case par réseau convolutif ; tourne sur Jetson Nano	95 % de détection du plateau, 92 % de classification des pièces ; 96 % « en conditions optimales » dans une réimplémentation	une case à la fois, en moins d'une seconde par position
chesscog (2021)	localisation du plateau par géométrie, occupation puis classe de pièce par réseaux	précision élevée sur son jeu de données ; dégradation quand l'angle de vue s'éloigne de la vue de dessus	les méthodes sont évaluées en vue de dessus : notre cas 2D est une vue de dessus parfaite
CVChess (2025)	transformée de Hough, redressement, 64 cases, réseau résiduel à 13 classes	98,9 % par case sur le domaine d'entraînement, moins bien hors domaine	le **décalage de domaine** (thèmes inconnus) est le risque à mesurer
Projets universitaires 2024-2025	rendus 3D synthétiques, puis photos réelles	environ 1,7 erreur par échiquier sur le synthétique ; performance insuffisante sur photos réelles	ne pas s'entraîner seulement sur du synthétique

Travail	Approche	Résultat rapporté	Enseignement
Jeux de données d'échiquiers **2D rendus**	100 000 images 400 × 400 avec FEN, 28 plateaux × 32 jeux de pièces	des classifieurs simples dépassent 99 % par case sur ce domaine	bon point de départ pour notre cas, à compléter par des captures réelles

3.3 Les briques que nous retiendrions

Étape	Technique	Pourquoi
Échantillonnage des images	**ffmpeg** avec détection de changement de scène (`select='gt(scene,0.3)'`) ou PySceneDetect, plutôt qu'une image toutes les 2 secondes	une vidéo de 20 minutes contient 60 à 150 positions distinctes, pas 600 : on divise le travail par 5 à 10
Détection de l'échiquier	d'abord **OpenCV** (détection de lignes de Hough, recherche d'une grille 8 × 8 régulière, homographie) ; un petit détecteur appris (type YOLO nano) si les thèmes « sans bordure » mettent la géométrie en échec	la grille 2D est régulière et axée : la géométrie classique suffit souvent, et elle ne coûte rien
Lecture de la position	découpage en 64 cases, **classifieur à 13 classes** (6 pièces × 2 couleurs + vide), réseau convolutif léger entraîné sur échiquiers rendus **et** sur des captures réelles annotées (thèmes Lichess, Chess.com, Chessbase, flèches, surlignages)	c'est l'approche de LiveChess2FEN et CVChess ; sur du 2D elle dépasse 99 % par case en domaine
Validation	**python-chess** : rejet des placements illégaux (deux rois, pions sur la première rangée, plus de 16 pièces par camp) ; cohérence temporelle : une position doit tenir au moins deux images successives	élimine la majorité des erreurs isolées sans modèle supplémentaire
Orientation	tester le placement et son miroir ; retenir celui qui est légal, ou les deux	gère l'échiquier vu côté Noirs

Ordre de grandeur de calcul : 30 à 50 ms par image sur un GPU d'entrée de gamme (L4), 10 à 20 fois plus sur CPU. Le décodage vidéo par ffmpeg pèse autant que la vision.

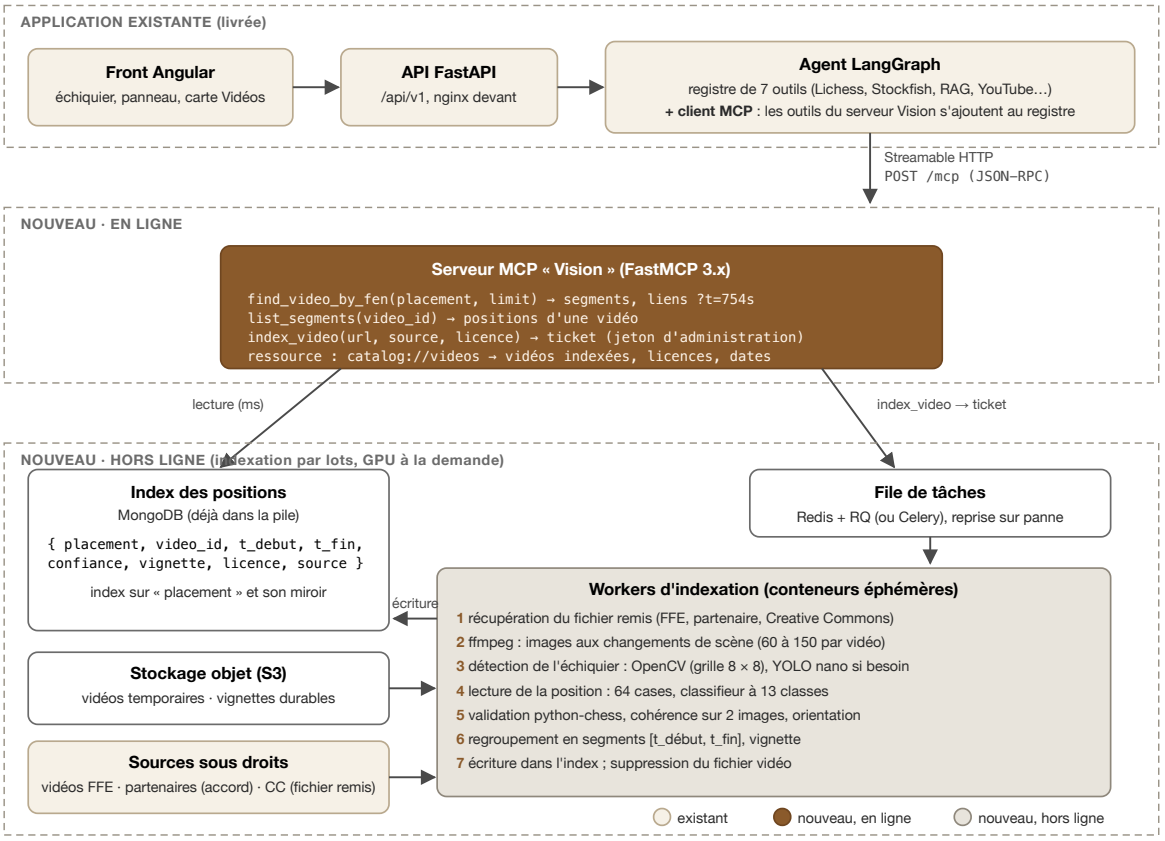
4. Architecture technique avec MCP

4.1 Pourquoi MCP

Le Model Context Protocol expose des **outils** et des **ressources** à n'importe quel agent, dans un contrat standard (schéma JSON des paramètres, description lisible par le modèle). Notre agent LangGraph consomme déjà sept outils par un registre interne ; le serveur Vision devient une **source d'outils supplémentaire** branchée par un client MCP, sans toucher au graphe. Le même serveur pourra servir d'autres usages FFE (site, bot, application mobile) et être remplacé ou déployé indépendamment.

Nous retiendrions **FastMCP** (version 3.x) en Python : un décorateur `@mcp.tool` sur une fonction typée suffit à publier un outil, les annotations génèrent le schéma, les fonctions asynchrones sont supportées, et le transport **Streamable HTTP** est recommandé pour un déploiement serveur (STDIO sert aux outils lancés localement ; SSE est déprécié).

4.2 Schéma d'architecture



Architecture : application existante, serveur MCP Vision en ligne, pipeline d'indexation hors ligne

Lecture du schéma : en haut, l'application livrée, dont l'agent devient client MCP ; au milieu, la seule brique nouvelle **en ligne**, le serveur FastMCP, qui ne fait que lire l'index ; en bas, le pipeline **hors ligne** qui transforme les fichiers remis par les ayants droit en segments, puis supprime les vidéos. Les flèches montrent les trois flux : requête MCP, lecture de l'index, écriture des segments par les workers.

4.3 Rôle de chaque brique

Brique	Rôle	Choix et justification
Client MCP dans l'agent	découvre les outils du serveur, les présente au modèle comme les autres	adaptateur MCP → `ToolSpec` existant : même politique de délai, de reprise et de disjoncteur que les sept outils ; repli sur la recherche texte si le serveur ne répond pas
Serveur MCP Vision	expose la recherche par position ; seul point d'entrée en ligne	FastMCP, HTTP, authentification par jeton pour `index_video` ; sans état, déployable en conteneur dans le `docker compose` actuel
Index des positions	répondre en quelques millisecondes à « quelles vidéos montrent ce placement ? »	MongoDB déjà présent dans la pile ; clé = placement normalisé ; 160 000 segments pèsent moins de 100 Mo
File de tâches et workers	indexer en lot, reprendre après panne, limiter le GPU aux créneaux utiles	Redis + RQ (simple) ou Celery ; les workers sont des conteneurs éphémères avec GPU
Stockage objet	fichiers vidéo le temps du traitement, vignettes des segments de façon durable	compatible S3 (Scaleway, OVHcloud) ; les vidéos sont **supprimées** après indexation, pour le droit et le coût
Modules de vision	détection, lecture, validation	chaque module a une interface stable (image → coordonnées ; vignette de case → classe) et se remplace sans toucher au serveur ni à l'agent

Tout l'existant est réutilisé : le registre d'outils (contrat, délai, reprise, disjoncteur) accueille le client MCP ; l'outil `find_opening_videos` reste le repli et fournit les métadonnées du catalogue ; MongoDB héberge l'index ; la carte « Vidéos pour réviser » lit les segments avec le bon horodatage ; le journal de décision mesure l'usage des segments et le taux de repli.

4.4 Modularité et évolutivité

- Changer de modèle de vision, c'est remplacer un worker. L'agent ne voit que des segments.
- Monter en charge, c'est ajouter des workers pendant la nuit d'indexation ; le service en ligne ne fait que des lectures d'index.
- Ajouter la transcription audio (§ 8) est un worker de plus qui enrichit les segments (« ici le présentateur dit : le cavalier attaque f7 »).
- Le serveur MCP peut porter demain d'autres outils (« positions similaires », « vidéos par thème ») sans changer de protocole.

5. Bénéfices attendus

Bénéfice	Pour qui	Comment le mesurer
Vidéo calée sur le coup : plus de parcours de 20 minutes	le jeune joueur	taux de clics sur les segments, temps avant lecture, enquête de satisfaction en club
Fonctionne hors théorie : si une vidéo a montré la position, l'index la connaît, nom d'ouverture ou pas	le joueur sorti des sentiers battus, cas où la recherche texte échoue	part des positions hors théorie avec au moins un segment
Un actif propre à la FFE : un index de positions sur un catalogue maîtrisé, réutilisable	la fédération	nombre de vidéos et de segments indexés, nombre d'applications consommatrices
Qualité pédagogique mesurable : chaque segment a une confiance et peut être validé par un entraîneur	la direction pédagogique	taux de segments validés, taux de signalements
Indépendance vis-à-vis de la recherche YouTube : moins de quota, résultats stables	l'équipe technique	unités d'API consommées par jour (aujourd'hui 201 par ouverture non cachée)

Hypothèse de valeur à vérifier en preuve de faisabilité : pour une position de la théorie courante (10 premiers coups des 12 ouvertures du corpus), **au moins un segment est trouvé dans 80 % des cas** avec un catalogue de 300 vidéos. En dessous, l'intérêt par rapport à la recherche texte devient marginal.

6. Limites et risques

6.1 Risques juridiques et de conformité (bloquants)

Risque	Analyse	Parade
Téléchargement interdit par les conditions d'utilisation de YouTube (accès au contenu uniquement par le lecteur, pas de téléchargement sans autorisation écrite de YouTube et des ayants droit)	s'applique à toute vidéo YouTube, y compris celles sous licence Creative Commons : la licence CC autorise la **réutilisation** du contenu, pas l'**accès au fichier** par un outil tiers	ne traiter que des fichiers **remis** par leurs auteurs : vidéos FFE, partenaires sous accord écrit, créateurs de vidéos CC sollicités pour fournir le fichier (la licence rend l'accord simple)
Droit d'auteur sur les images extraites	les vignettes de segments sont des extraits ; l'index lui-même (positions et horodatages) n'est pas protégé	ne conserver que des vignettes réduites, mention de la source et de la licence, suppression sur demande
Données personnelles	aucune donnée de joueur n'entre dans le pipeline ; les sessions de l'agent restent celles d'aujourd'hui	registre des traitements inchangé
Dépendance à la plateforme	les liens `t=` et le lecteur intégré dépendent de YouTube	les segments stockent aussi l'identifiant de la vidéo source chez le partenaire : un hébergement FFE reste possible

6.2 Risques techniques

Risque	Probabilité	Impact	Parade
Décalage de domaine : thèmes de pièces inconnus, flèches, surlignages, curseur	élevée	positions fausses ou manquées	jeu d'entraînement mêlant rendus synthétiques (28 plateaux × 32 jeux de pièces) et 1 000 à 2 000 captures réelles annotées ; validation de légalité ; seuil de confiance ; cohérence temporelle
Échiquiers partiels, animés ou très petits (incrustation en coin)	moyenne	segments manqués	détecteur appris en complément de la géométrie ; accepter de manquer les incrustations
Plateaux physiques filmés	faible dans notre corpus	hors périmètre	ne pas traiter ; signaler la vidéo comme non indexable
Positions ambiguës (trait, roques)	certaine	deux positions confondues	assumé : indexation du placement seul (§ 2.3)
Dérive des outils externes (format des liens, lecteur)	faible	liens cassés	tests de bout en bout périodiques

6.3 Risques business

Risque	Analyse	Parade
Couverture insuffisante : sans droits, le catalogue reste petit et l'index ne connaît pas la position du joueur	c'est le risque qui décide de la valeur	fixer un seuil (300 vidéos sous droits) avant d'industrialiser ; repli automatique sur la recherche texte
Investissement pour un gain marginal	si les créateurs partenaires fournissent déjà un PGN horodaté, la vision est superflue	évaluer l'alternative 2 (§ 8) avec les premiers partenaires
Coût humain sous-estimé	l'annotation et les accords prennent plus de temps que le code	provisionner 20 % de marge ; jalons avec critères d'arrêt
Relations avec les créateurs	indexer sans accord abîmerait la relation	accord écrit, attribution visible, possibilité de retrait

7. Faisabilité et coûts

7.1 Hypothèses

Paramètre	Hypothèse basse	Hypothèse haute
Catalogue	500 vidéos	2 000 vidéos
Durée moyenne	20 min	25 min
Images analysées (changements de scène)	100 par vidéo → 50 000	150 par vidéo → 300 000
Temps de vision par image (GPU L4)	50 ms	50 ms
Décodage ffmpeg	0,5 × durée réelle sur 4 cœurs	idem
Nouvelles vidéos par mois en régime de croisière	20	100
Prix GPU L4 à la demande	0,9 €/h (Scaleway, OVHcloud) ; 0,4 à 0,5 €/h chez des fournisseurs spécialisés	idem
VM 2 vCPU / 8 Go	30 à 40 €/mois	idem
Stockage objet	0,015 €/Go/mois ; sortie 0,01 €/Go au-delà de 75 Go	idem

Les prix sont ceux relevés en octobre 2026 chez des fournisseurs européens ; ils varient de 10 à 20 % selon la région et le mode de facturation.

7.2 Coûts de construction (build)

Machine, ponctuel

Poste	Basse	Haute	Calcul
Vision GPU, indexation initiale	3 €	15 €	50 000 × 50 ms = 0,7 h ; 300 000 × 50 ms = 4,2 h ; × 0,9 €/h, arrondi avec les relances
Décodage et détection de scènes (CPU)	10 €	60 €	500 × 20 min × 0,5 = 83 h de CPU 4 cœurs ; 2 000 × 25 min × 0,5 = 417 h ; VM à 0,1 à 0,15 €/h
Stockage temporaire des fichiers	3 €	15 €	500 × 300 Mo = 150 Go ; 2 000 × 400 Mo = 800 Go ; quelques jours seulement
Entraînement et évaluation du classifieur	20 €	50 €	20 à 50 h de GPU, plusieurs itérations
Total machine	**≈ 40 €**	**≈ 140 €**	négligeable devant l'humain

Humain, en jours de travail (un développeur confirmé, appui ponctuel d'un entraîneur pour l'annotation et la validation)

Phase	Contenu	Basse	Haute
0. Cadrage et droits	recensement des vidéos FFE, premiers accords partenaires, modèle d'accord, sollicitation des créateurs CC	5	10
1. Preuve de faisabilité	20 vidéos, 2 000 images annotées, entraînement du classifieur, mesure de précision, décision	10	15
2. MVP	pipeline complet, serveur MCP (3 outils, 1 ressource), client MCP dans l'agent, 200 vidéos indexées, carte Vidéos adaptée	15	25
3. Industrialisation	file de tâches, workers GPU à la demande, reprise sur panne, supervision, validation par les entraîneurs, retrait sur demande	10	15
4. Enrichissement	transcription audio des segments (§ 8), recherche de positions proches	5	10
Total		**45 jours**	**75 jours**

En coût complet, à 500 à 700 € par jour (prestation) ou 350 à 450 € (interne), le build représente **16 000 à 52 000 €**. C'est là que se décide le projet, pas sur la machine.

7.3 Coûts de fonctionnement (opex, par mois)

Poste	Basse	Haute	Remarque
Serveur MCP + index	0 à 40 €	40 €	0 € si hébergé sur la VM backend existante ; 1 VM 2 vCPU / 8 Go sinon
Indexation des nouvelles vidéos (GPU + CPU à la demande)	2 €	15 €	20 vidéos × 5 min de GPU ; 100 vidéos × 5 min
Stockage durable (vignettes, index)	1 €	5 €	160 000 vignettes × 20 Ko = 3,2 Go ; index < 1 Go
File de tâches (Redis)	0 €	10 €	sur la même VM, ou service géré
API YouTube	0 €	0 €	métadonnées seulement, dans le quota gratuit
Supervision, sauvegardes	5 €	20 €	
Maintenance humaine	1 jour	3 jours	reprise des vidéos en échec, mises à jour, validations
Total machine	**≈ 10 à 50 €**	**≈ 90 €**	

À comparer : un GPU réservé en permanence coûterait 650 €/mois pour rien. Le choix du « GPU à la demande, en lot » est ce qui rend l'opex marginal.

7.4 Verdict de faisabilité

Critère	Verdict
Technique	**faisable** avec des briques éprouvées ; incertitude sur la précision hors domaine, à lever en phase 1
Coût machine	**négligeable** (dizaines d'euros en build, dizaines d'euros par mois)

Critère	Verdict
Coût humain	**significatif** (45 à 75 jours), concentré sur l'annotation, l'intégration et l'industrialisation
Juridique	**conditionne tout** : sans fichiers remis par les ayants droit, pas de projet
Valeur	**à prouver** : dépend de la taille du catalogue ; seuil proposé de 300 vidéos sous droits

8. Alternatives

8.1 Transcription audio et reconstruction des coups

Transcrire chaque vidéo (API de transcription à environ 0,006 $ la minute, soit 60 $ pour 500 vidéos de 20 min, 300 $ pour l'hypothèse haute ; ou un modèle Whisper ouvert sur GPU), puis demander à un modèle de langage de repérer les coups annoncés (« cavalier f3 », « on prend en d5 ») et de rejouer la partie avec python-chess pour obtenir des positions horodatées.

Pour	Contre
pas de vision, pas de GPU dédié, s'appuie sur ce que nous savons faire (LLM, python-chess)	dépend de la qualité du commentaire : coups non annoncés, « on joue ici », variantes sautées
donne en plus le **contexte** parlé, que l'image n'a pas	les horodatages sont ceux de la parole, moins précis que l'image
coût machine très bas	les mêmes contraintes de droits sur le fichier audio

Verdict : excellente **complément** de la vision (elle enrichit les segments de ce qui est dit), **insuffisante seule** sur les vidéos où le présentateur ne dicte pas les coups.

8.2 Chapitres YouTube, descriptions et PGN fournis par les créateurs

Beaucoup de créateurs mettent dans la description la liste des coups, un PGN ou des chapitres horodatés (« 03:12 variante 4.Cg5 »). L'API YouTube donne descriptions et chapitres **sans télécharger la vidéo**. Un partenariat demande au créateur un PGN horodaté (export d'un logiciel d'analyse, quelques minutes de travail par vidéo).

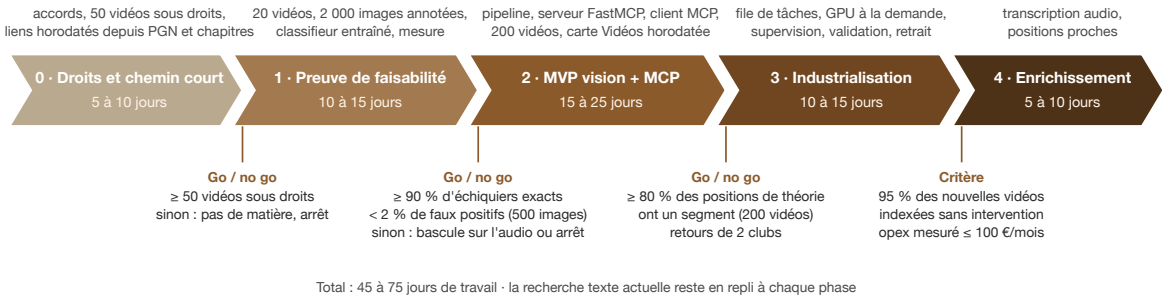
Pour	Contre
aucun risque juridique, aucun GPU, quelques jours de développement	couverture limitée aux vidéos bien documentées ou aux partenaires
précision parfaite quand le PGN existe	demande un effort aux créateurs ; variable
peut démarrer en deux semaines dans l'outil existant	n'adresse pas le stock de vidéos existantes non documentées

Verdict : **à faire d'abord**, quoi qu'il arrive. C'est le chemin le plus court vers des liens horodatés, et il mesure l'appétence des créateurs. La vision ne se justifie que pour le stock de vidéos non documentées.

8.3 Comparaison

Critère	Vision (cette note)	Transcription audio	Chapitres et PGN
Précision des horodatages	image près (± 2 s)	phrase près (± 10 s)	parfaite si fournie
Couverture possible	toute vidéo avec échiquier à l'écran **et** fichier disponible	toute vidéo commentée **et** fichier disponible	vidéos documentées ou partenaires
Risque juridique	fort sans accord	fort sans accord	nul
Build	45 à 75 jours	15 à 25 jours	5 à 10 jours
Opex	10 à 90 €/mois	10 à 60 €/mois	≈ 0
Dépendance à un modèle de vision	oui	non	non

9. Étapes de développement et recommandation



Cinq phases avec leurs livrables et leurs critères d'arrêt

Phase	Livrables	Critère d'arrêt (go / no go)
0. Droits et chemin court	modèle d'accord, 50 vidéos sous droits (FFE, partenaires, CC sollicités), **alternative 8.2 livrée** dans l'outil existant (liens horodatés depuis les descriptions et PGN)	moins de 50 vidéos obtenues → arrêt : la vision n'aura pas de matière
1. Preuve de faisabilité	20 vidéos, 2 000 images annotées par un entraîneur, classifieur entraîné (rendus + réel), mesure : exactitude par case, par échiquier, taux de faux positifs après validation	**≥ 90 % d'échiquiers exacts et < 2 % de faux positifs** ; sinon, arrêt ou bascule sur 8.1
2. MVP	pipeline hors ligne, serveur FastMCP (3 outils, 1 ressource), client MCP dans l'agent avec repli texte, 200 vidéos indexées, carte Vidéos avec horodatage	≥ 80 % des positions de la théorie courante ont un segment ; retours de 2 clubs
3. Industrialisation	file de tâches, GPU à la demande, supervision, validation et retrait, documentation d'exploitation	95 % des nouvelles vidéos indexées sans intervention ; opex mesuré ≤ 100 €/mois
4. Enrichissement	transcription des segments (8.1), positions proches, statistiques d'usage	gain mesuré sur le temps avant lecture

Recommandation. Faire la phase 0 immédiatement, parce qu'elle livre de la valeur sans risque (liens horodatés depuis les PGN et chapitres) et parce qu'elle répond à la seule question qui compte : la FFE obtiendra-t-elle des fichiers vidéo sous droits ? Lancer la phase 1 dès 50 vidéos obtenues, avec son critère chiffré. Ne décider du MVP qu'avec le résultat de la phase 1 en main. Dans tous les cas, garder la recherche texte actuelle en repli : elle fonctionne, elle est mesurée, et elle couvre les cas que l'index ignorera.

Sources consultées

- LiveChess2FEN : article (arXiv 2012.06858) et page NVIDIA Jetson (95 % de détection, 92 % de classification) ; réimplémentation universitaire (96 % en conditions optimales).
- chesscog (Wölflein et Arandjelović, 2021), cité par VICE : View-Invariant Chess Estimation (2023) pour la dégradation hors vue de dessus.
- CVChess : A Deep Learning Framework for Converting Chessboard Images to FEN (arXiv 2511.11522) : 98,93 % par case en domaine, moins hors domaine ; jeu de données ChessReD.
- Projets CS231N (Stanford, 2024-2025) : rendus synthétiques et photos réelles.
- Jeu de données d'échiquiers 2D rendus : 100 000 images, 28 plateaux, 32 jeux de pièces.
- FastMCP : documentation officielle (gofastmcp.com), outils, transports (Streamable HTTP recommandé, SSE déprécié), version 3.2.x.
- YouTube Data API v3 : paramètre `videoLicense=creativeCommon` du point d'entrée `search.list` ; conditions d'utilisation YouTube (accès au contenu par le lecteur, téléchargement interdit sans autorisation écrite).
- Prix relevés en octobre 2026 : GPU L4 à la demande 0,88 à 1,00 €/h (Scaleway, OVHcloud), 0,39 à 0,49 $/h (RunPod) ; VM OVHcloud b3-8 (2 vCPU, 8 Go) 28 à 44 €/mois selon la source ; stockage objet Scaleway 0,0146 €/Go/mois, sortie 0,01 €/Go au-delà de 75 Go ; transcription OpenAI gpt-4o-transcribe 0,006 $/min, gpt-4o-mini-transcribe 0,003 $/min.